

储能测试与评价

基于LSTM-DaNN的动力电池SOC估算方法

王一全¹, 黄碧雄¹, 严晓², 刘新田¹, 王影¹, 刘双宇¹, 徐华源¹

(¹上海工程技术大学机械与汽车工程学院, 上海 201600; ²上海玖克生储能科技有限公司, 上海 201600; ³浙江华云信息科技有限公司, 浙江 杭州 310051)

摘要: 针对动力电池荷电状态 (state of charge, SOC) 的估算问题, 利用长短期记忆 (LSTM) 循环神经网络建立 SOC 估算模型, 以实验室恒流放电数据训练模型并测试, 测试最大绝对误差为 2.7%。进一步以 FSEC 赛车电池实测数据验证, 最大测试误差为 3.9%。但在工程应用时, 考虑到实际运行过程中的环境复杂性以及不同驾驶习惯对动力电池造成的不一致性, 需要根据车辆实际行驶工况数据对其进行训练与测试, 但是由于该数据中的 SOC 直接由 BMS 报文解析而来, 无法确定 BMS 内的 SOC 算法是否准确, 故不能直接用作训练模型时的标签, 此时需计算出正确的训练标签或借助已有标签的模型, 在其基础上根据实际运行数据对其模型参数进行动态调整。为解决无标签数据的训练问题, 本文采取第二种方法, 首次提出将迁移学习中的领域自适应网络 (DaNN) 与 LSTM 组合形成 LSTM-DaNN 的 SOC 估算算法, 利用有标签数据预先训练好 LSTM 模型, 再将其模型参数迁移至 LSTM-DaNN, 最后综合有标签与无标签数据一起对 LSTM-DaNN 模型进行训练。测试结果表明 LSTM-DaNN 可以在没有实际行驶工况标签 (SOC) 的情况下完成训练, 最大测试误差为 4.8%, 相比模型自适应调整前误差下降了 14.1%, 且保证绝对误差 < 5%, 满足实际需求。

关键词: 荷电状态 (SOC); 长短期记忆 (LSTM); 迁移学习; 领域自适应网络 (DaNN)

doi: 10.19799/j.cnki.2095-4239.2020.0200

中图分类号: TM 912.9

文献标志码: A

文章编号: 2095-4239 (2020) 06-1969-07

SOC estimation method of power battery based on LSTM-DaNN

WANG Yiquan¹, HUANG Bixiong¹, YAN Xiao², LIU Xintian¹, WANG Ying¹, LIU Shuangyu¹, XU Huayuan¹,

(¹School of Mechanical and Automotive Engineering, Shanghai University of Engineering Science, Shanghai 201600, China;

²Shanghai Makesens Energy Storage Technology Co., Ltd., Shanghai 201600, China; ³Zhejiang Huayun Information Technology Co. Ltd., Hangzhou 310051, Zhejiang, China)

Abstract: In this study, a long - short-term memory (LSTM) recurrent neural network is used to establish an estimation model of the state of charge (SOC) to estimate the SOC of power batteries. The model is trained and tested with a laboratory's constant current discharge data. The maximum absolute error is 2.7%. A further verification by the FSEC racing battery measured data shows a maximum test error of 3.9%. However, considering the complexity of the environment during the actual operation and the inconsistency caused by different driving habits to the power battery in engineering applications, training and testing must be performed according to the actual driving conditions of the vehicle. The SOC in driving conditions are directly translated from the battery management system (BMS) message; hence, we cannot affirm whether the SOC algorithm in the BMS is accurate. Consequently, the SOC in the driving conditions cannot be used as a label while training the model. At this time, the correct training label must be calculated or the existing model trained by the labeled data must be used. Its

收稿日期: 2020-06-02; 修改稿日期: 2020-07-16。

第一作者: 王一全 (1996—), 男, 硕士研究生, 研究方向为动力电池状态预测算法与新能源汽车大数据, E-mail: w1qnick@163.com; 联系人:

黄碧雄, 硕士, 实验师, 研究方向为新能源汽车动力电池, E-mail: hbxzc@hotmail.com。

model parameters must then be dynamically adjusted based on the actual operating unlabeled data. This study takes the second method to solve the training problem of unlabeled data, proposing for the first time the combination of the domain adaptive neural network (DaNN) in transfer learning with LSTM to form the SOC estimation algorithm of LSTM-DaNN using the labeled data to train the LSTM model in advance, transfer its model parameters to LSTM-DaNN, and finally train the LSTM-DaNN model by combining the labeled and unlabeled data. The result shows that LSTM-DaNN can complete the training without the label of the actual driving condition (i.e., SOC) and ensure an absolute error of 4.8%. Compared with the model before the adaptive adjustment, the error decreases by 14.1%, and the absolute error is guaranteed to be <5%, meeting actual needs.

Key words: state of charge(SOC); long short-term memory(LSTM); transfer learning; domain adaptive neural network(DaNN)

动力电池荷电状态(state of charge, SOC)是电池管理系统(BMS)的重要参数, 对其准确估算直接关系到电池充放电控制和电动汽车的优化管理^[1-3]。动力电池 SOC 被用来直接反映电池的剩余电量状态, 估计电动汽车的续航里程。美国先进电池联合会(USABC)将其定义为: 电池在一定放电倍率下, 剩余电量与相同条件下额定容量的比值^[4], 公式见式(1)

$$\text{SOC} = \frac{Q}{C} \quad (1)$$

其中, Q 为电池的剩余电量, C 为电池可以放出的总电量。

SOC 不能直接通过设备测出, 必须通过测量电流、电压、温度等参数, 并建立合适的电化学模型或数学模型进行估算。其估算的影响因素很多且关系复杂, 例如环境温度、电池健康状态(state of health, SOH)、一致性问题等。目前常用的 SOC 估算方法有: 开路电压法^[5]、安时积分法^[6]、内阻法^[7]、卡尔曼滤波法^[8]、神经网络法^[9]等。其中开路电压法精度较高, 计算简单, 但要求电池长时间静置以达到电压问题, 实时估算时无法使用; 安时积分法是在工程实践中最常用的方法, 其计算简单, 但不能估算初始值, 存在累计误差; 内阻法在实际应用中存在难以测量到电池直流内阻的问题; 卡尔曼滤波法运算量大, 精度依赖于等效电路模型的准确性, 当电池状态变化时, 其精度降低; 神经网络法属于纯数据驱动的机器学习方法^[10], 不需要专门设计实验与电路模型, 仅凭借历史数据即可挖掘出电池参数与 SOC 之间的关系, 但是需要有准确的 SOC 值当作模型训练标签, 且精度依赖于训练数据样本, 当使用条件变化时需及时调整模型参数。

针对神经网络法存在的问题, 本文提出将 SOC 估算模型视为时间序列模型, 综合考虑一段时间内的电池特征参数, 建立长短期记忆(LSTM)循环神经网络的 SOC 估算模型。当车辆实际行驶工况与训练样本差距较大时, 需结合实际行驶工况数据对模型参数进行调整修正, 但实际工况下的 SOC 直接通过 BMS 报文解析得来, 无法用作训练时的标签。针对这一无标签数据训练问题, 本文首次提出将迁移学习中的领域自适应网络(DaNN)引入 SOC 估算方法中, 形成 LSTM-DaNN 算法, 借助有标签数据训练无标签数据, 解决 SOC 估算方法中传统机器学习算法在工程应用时因缺少训练标签而难以落地的问题。

1 LSTM 计算 SOC

1.1 LSTM 循环神经网络

循环神经网络(RNN)与多层感知机(MLP)等其他神经网络不同, 是一类用于处理序列数据的神经网络^[11], 其结构如图1所示。




图1 RNN网络结构

Fig.1 RNN network structure

将RNN展开后的长度称为timestep, 由图1可知, timestep= t , 对于某一时刻的输出 h_t , 不仅仅只由这一时刻的输入 x_t 决定, 还与之前时刻的状态有关。将图1用数学公式表达为

$$h_t = f_w(h_{t-1}, x_t) \quad (2)$$

式中, h_t 为当前时刻输出, h_{t-1} 为上一时刻输出, x_t 为当前时刻输入, f_w 为包含网络参数的映射函数。由式(2)可知, RNN 实则是一个递归运算, 当网络循环到最后一次输出 h_t 时, 其包含了 $h_0 \sim h_{t-1}$ 的所有信息。但是, 当 timestep 很大时, 在误差梯度从 h_t 反向传播到 h_0 的过程中, 会受到 timestep 次幂的影响, 产生梯度爆炸或梯度消失的问题, 这说明 RNN 不具备长期记忆, 而只具备短期记忆。为解决这一问题, 在图1的 RNN 单元 A 中增加3个门控单元(gate), 分别是输入门(input gate)、遗忘门(forget gate)和输出门(output gate), 如图2所示, 便成为了长短期记忆(long short-term memory)循环神经网络结构, 其网络结构如图3所示。




图2 LSTM单元结构

Fig.2 LSTM cell structure




图3 LSTM网络结构

Fig.3 LSTM network structure

图3中的3个 σ 函数分别控制着LSTM单元结构里的3个门, 由 σ 函数式(3)可知

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (3)$$

其函数值在(0, 1)范围内, 可起到门控作用, 表示让对应信息通过的权重, 例如0表示“不让任何信息通过”, 1表示“让所有信息通过”。故可将LSTM的门定义为

$$\text{gate}_{f,i,o}[h_{t-1}, x_t] = \sigma(W_{f,i,o}[h_{t-1}, x_t] + b_{f,i,o}) \quad (4)$$

式中, f, i, o 分别表示遗忘门、输入门和输出门, W, b 是在不同门中网络需要学习的参数。将每个LSTM单元根据图3的结构整理为LSTM计算公式

$$\begin{aligned} f_t &= \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \\ i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \\ C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t \\ o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned} \quad (5)$$

其中, \tilde{C}_t 表示前一时刻单元状态, C_t 表示经过遗忘门更新后的单元状态, h_t 表示当前单元的输出, h_{t-1} 表示前一时刻单元的输出。

1.2 LSTM计算SOC结构

当LSTM循环神经网络应用于锂电池SOC估算时, 根据1.1节的定义, 将电池数据视为时间序列数据, 在确定的timestep长度上训练模型, 本文取timestep=30, 即计算当前时刻SOC时需要用到前30 s的数据, 模型结构如图4所示。




图4 LSTM计算SOC结构

Fig.4 LSTM calculation structure of SOC

1.3 数据预处理

本节使用数据为实验室恒流充放电数据, 实验对象为2并16串的万向磷酸铁锂电池模组, 额定容量70 A·h, 实验设备为Arbin EVTS500, 放电倍率分别为0.25 C、0.5 C、0.75 C、1 C, 实验温度10~40 °C, 模组上有8个温度传感器。本文首先将所有放电过程根据timestep=30切分成一个个训练样本, 每个样本包含30 s的放电数据, 其中训练集包含305736个样本, 测试集包含131029个样本。其次, 本文选取模组电流、模组电压、电压极差(最高单体电压-最低单体电压)和平均温度作为模型输入特征, 其中电压极差可以反映模组的一致性和SOH。由于为实验室满充满放数据, 故可使用式(1)计算出真实SOC作为模型训练时的标签。

为消除输入变量之间的量纲影响,以解决数据指标之间的可比性,将所有输入特征进行最大-最小标准化处理

$$x' = \frac{x - \min A}{\max A - \min A} \quad (6)$$

式中, $\max A$ 和 $\min A$ 分别为所有训练数据中的最大值和最小值, 处理后的所有特征值均在(0, 1)范围内。

1.4 实验结果分析

本文使用 Pytorch 深度学习框架搭建 LSTM 循环神经网络, 其框架如图 5 所示。




图5 LSTM计算SOC框架

Fig.5 LSTM calculation framework of SOC

确定超参数 $\text{hidden_size}=128$, $\text{batch_size}=4$, $\text{num_layers}=1$, 计算误差时损失函数选用最大均方误差MSE, 误差反向传播时选用Adam优化器, 模型迭代到20次时已收敛。将测试数据代入训练好的模型进行测试, 结果如图6所示。




图6 LSTM计算SOC误差

Fig.6 LSTM error of SOC

图中红线为根据式(1)计算出的真实SOC, 蓝线为LSTM模型估算出的SOC, 最大绝对误差为2.7%。

1.5 实测数据结果分析

为进一步验证该模型在实测数据情况下的表现, 本节使用T-BOX采集大学生电动方程式赛车大赛(FSEC)参赛赛车数据。该赛车动力电池由109个明达EPC070180SP三元锂电池单体串联构成, 单体额定容量为18 A·h。采集其在赛道上行驶60圈的

数据作为实测数据, 验证本文LSTM模型在实测数据中的表现。选取其中40圈为训练样本, 20圈为测试样本, 其中1圈测试结果如图7所示。




图7 LSTM实测数据误差

Fig.7 LSTM error of real data

图7中SOC绝对误差最大为3.9%, 结果表明在训练数据充足, 且测试数据分布与训练数据分布差距不大的情况下, LSTM模型计算SOC有不错的精度。

2 LSTM-DaNN计算SOC

2.1 LSTM计算SOC存在的问题

由1.4节可以看到, LSTM在计算SOC时具有很高的精度, 但训练数据与测试数据均来自恒流放电实验, 数据分布差别不大。当工程应用时, 需根据车辆实际行驶工况对模型参数进行调整。本节依旧使用1.3节中的万向电池模组, 根据国标《GB/T31484—2015 电动汽车用动力蓄电池安全要求及试验方法》中的纯电动商用车充放电工况, 且每隔15 s采集一次, 来模拟车辆实际行驶工况, 以下简称实际工况。将实际工况数据按1.3节所述方式预处理, 共包含27067个训练样本与11600个测试样本。当把实际工况测试样本数据直接代入1.4节中由恒流放电数据建立的LSTM模型测试时, 最大绝对误差达到18.9%, 如图8所示。

因此现需根据实际工况数据, 对LSTM模型参数进行调整。由于车辆实际使用中的SOC直接由BMS报文解析而来, 故此SOC并不是真实值, 不




图8 实际工况测试LSTM模型

Fig.8 Test LSTM under actual working conditions

能用作模型训练时的标签, 而通过按时积分法等求出实际使用时的真实 SOC 也很困难。为解决实际工况下无标签的问题, 本文引入迁移学习中的领域自适应网络(DaNN), 利用有标签数据(本文中第1.1节的恒流放电数据)及根据该数据已训练好的 LSTM 模型, 辅助训练无标签数据(本文中第1.2节的实际工况数据), 实现对 LSTM 模型参数的调整。

2.2 迁移学习

迁移学习, 是指利用数据、任务或模型之间的相似性, 将在旧领域学习过的模型, 应用于新领域的一种学习过程^[12]。这里将旧领域定义为源领域(source domain, $D_s = \{x_i, y_i\}_{i=1}^n$, 本文中即恒流放电数据), 新领域定义为目标领域(target domain, $D_t = \{x_j\}_{j=n+1}^{n+m}$, 本文中即实际工况数据)。迁移学习的目的就是要借助 D_s 的知识(标签, y_i), 来学习目标域 D_t 的知识(标签, y_j)。

迁移学习方法基本分为三类: 数据分布自适应法、特征选择法、深度迁移学习。数据分布自适应法是将源域与目标域做一些变换, 将不同的数据分布的距离拉近; 特征选择法是假设源域与目标域在某些公共特征上数据分布一致, 目标是寻找公共特征。这两种方法都需从头开始一起训练源域与目标域数据, 当数据量增大时会耗费大量时间。深度迁移学习与其相比, 可以直接迁移源域已有的模型参数, 相当于使模型已具备了源域的“知识”, 不需从头开始学习, 会节省大量训练时间。

使用深度神经网络进行迁移学习的方法称为深度迁移学习, 其损失函数定义为

$$\ell = \ell_c(D_s, y_s) + \lambda \ell_A(D_s, D_t) \quad (7)$$

其中, ℓ 表示网络的最终损失; $\ell_c(D_s, y_s)$ 表示网络在有标注数据上的损失(本文中为1.4节的MSE); $\ell_A(D_s, D_t)$ 表示网络的自适应损失, 反映了源域数据与目标域数据的分布差异, 自适应的目标是将源域与目标域数据从低维上升到高维空间, 最小化两个分布之间的差异; λ 是权衡两部分的权重参数。

2.3 自适应网络(DaNN)

DaNN 网络采用 MMD 作为自适应损失 $\ell_A(D_s, y_i)^{[13]}$, 最大平均差异(MMD)用来度量两个不同但相关的分布的距离, 定义为

$$\text{MMD}(X, Y) = \left\| \frac{1}{n} \sum_{i=1}^n \Phi(x_i) - \frac{1}{m} \sum_{j=1}^m \Phi(y_j) \right\|_H^2 \quad (8)$$

其中, H 表示分布的距离是由 $\Phi()$ 将数据映射

到再生希尔伯特空间(RKHS)中进行度量的。

将 MMD 展开得到式(9):

$$\text{MMD}(X, Y) = \left\| \frac{1}{n^2} \sum_i \sum_i \Phi(x_i) \Phi(x'_i) - \frac{2}{nm} \sum_i \sum_j \Phi(x_i) \Phi(y_j) + \frac{1}{m^2} \sum_j \sum_j \Phi(y_j) \Phi(y'_j) \right\| \quad (9)$$

从式(9)可以看到 MMD 的计算需要先找到合适的映射函数 $\Phi()$, 其次求向量内积。由于 $\Phi()$ 难以定义, 故引入核函数 $k()$, 核函数不需要显式地表示映射函数, 可以直接通过低维数据计算出高维向量内积, 故将式(9)改写为

$$\text{MMD}(X, Y) = \left\| \frac{1}{n^2} \sum_i \sum_i k(x_i, x'_i) - \frac{2}{nm} \sum_i \sum_j k(x_i, y_j) + \frac{1}{m^2} \sum_j \sum_j k(y_j, y'_j) \right\|_H \quad (10)$$

其中, $k(u, v)$ 为高斯核函数, 高斯核可以将数据从低维映射到无穷维空间

$$k(u, v) = e^{-\frac{\|u - v\|^2}{\sigma}} \quad (11)$$

2.4 LSTM-DaNN 计算 SOC 结构

结合第一部分中 LSTM 模型的损失函数和2.3节中的 MMD, 将式(7)改写为 LSTM-DaNN 模型的损失函数

$$\ell_{\text{LSTM-DaNN}} = \text{MSE}(D_s, y_s) + \lambda \text{MMD}^2(D_s, D_t) \quad (12)$$

式中, 第一部分反映本文恒流放电数据(有标签)在 LSTM-DaNN 中的误差, 第二部分反映本文实际工况数据(无标签)与恒流放电数据(有标签)在高维空间的差距。该损失函数的目的是将无标签与有标签数据映射到高维空间中, 使其分布距离尽可能小, 这样有标签数据在高维空间中就可以辅助无标签数据, 量化其误差, 对模型进行训练。

本文将第一节已用有标签数据建立好的 LSTM 模型参数迁移到 LSTM-DaNN 的 LSTM 层, 设为其初始值, 并在其后加入 MMD 层度量源域和目标域数据分布的差异, 其网络结构如图9所示。

LSTM-DaNN 解决 SOC 建模时无标签问题的完整流程如图10所示, 其程序流程图如图11所示。

2.5 实验结果分析

本文使用1.3节中的恒流放电数据作为源领域数据, 2.1节中的实际工况数据作为目标领域数据(无标签), 对 LSTM-DaNN 模型进行训练, 损失函数为式(12), 模型迭代到28次时收敛, 实现了根据




图9 LSTM-DaNN计算SOC框架

Fig.9 LSTM-DaNN calculation framework of SOC

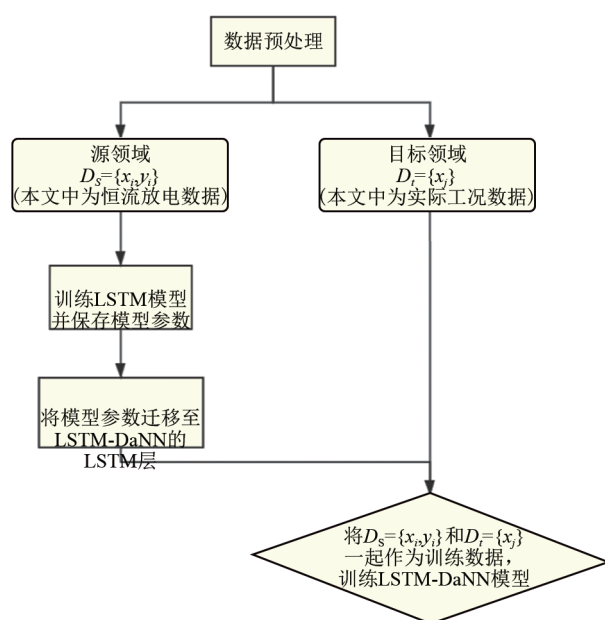


图10 LSTM-DaNN流程图

Fig.10 LSTM-DaNN flow chart

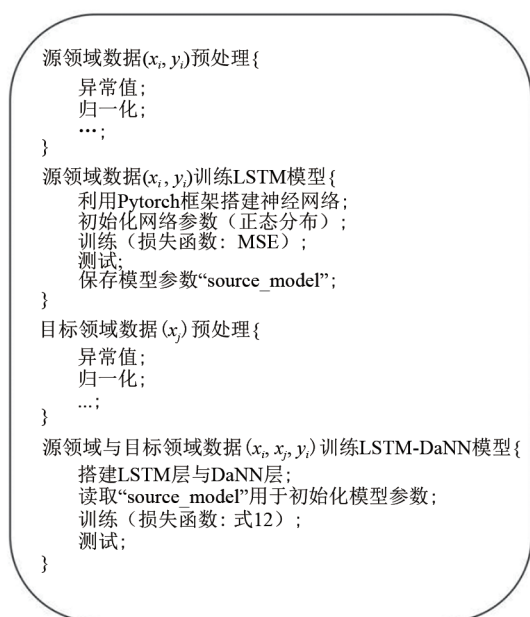


图11 LSTM-DaNN程序流程图

Fig.11 LSTM-DaNN program flow chart

实际工况数据,对已有模型参数的自适应调整。将实际工况的测试集代入模型进行测试,由于是实验室模拟的车辆实际行驶工况数据,故可根据式(1)计算出真实SOC来验证模型的精度,测试结果如图12所示。




图12 LSTM-DaNN计算SOC误差

Fig.12 LSTM-DaNN error of SOC

图中红线为实际工况下根据式(1)计算出的真实SOC,蓝线为LSTM-DaNN模型估算出的实际工况下SOC,最大绝对误差为4.8%,相比于自适应调整前的误差18.9%,下降了14.1%。结果表明在没有实际工况标签的情况下,通过LSTM-DaNN模型,可以通过有标签数据对其辅助进行训练,并调整模型参数以适合实际工况,保证实际工况下估算误差<5%,满足实际使用需求。

3 结论

本文首先将电池充放电数据视为时间序列数据,建立LSTM的SOC估算模型,经训练和测试,最大绝对误差为2.7%。为进一步验证模型的估算精度,使用FSEC赛车电池实测数据进行深度迁移学习,测试结果最大绝对误差为3.9%,拥有较高的SOC估算精度。

其次针对实际工况下,需要对模型参数进行调整,但工程应用时无准确SOC可用作训练标签的问题,首次提出将迁移学习中的领域自适应网络(DaNN)与LSTM组合形成LSTM-DaNN的SOC估算算法,实现实际工况下,以有标签数据辅助训练无标签数据,完成对模型参数的自适应调整。结果表明,LSTM-DaNN在实际工况无标签的情况下,可以完成对模型参数的调节,最大绝对误差为4.8%,相比于自适应调节前的最大绝对误差18.9%,下降了14.1%,效果显著,且保证误差<5%,满足车辆实际驾驶需求。本算法在实际工况中具有可行性,在需要根据实际数据对模型

参数进行调整的情况下相比其他方法节约了训练时间, 并为深度学习方法估算SOC提供了项目落地方案。

参考文献

- [1] 孙巍. 国内近几年锂电池SOC估计方法综述[J]. 福建质量管理, 2019(3): 248.
SUN Wei. Overview of SOC estimation methods for lithium batteries in China in recent years[J]. Fujian Quality Management, 2019(3): 248.
- [2] 陈元丽, 赵振东, 陈素娟, 等. 动力锂电池SOC估算方法综述[J]. 汽车科技, 2019(5): 65-69.
CHEN Yuanli, ZHAO Zhendong, CHEN Sujuan, et al. Overview of SOC estimation methods for power lithium batteries[J]. Automotive Technology, 2019(5): 65-69.
- [3] 胡耘. 动力电池荷电状态(SOC)估算方法综述[J]. 汽车实用技术, 2019(8): 36-38.
HU Yun. Overview of estimation method of power battery state of charge(SOC)[J]. Automotive Practical Technology, 2019(8): 36-38.
- [4] 沈佳妮, 贺益君, 马紫峰. 基于模型的锂离子电池SOC及SOH估计方法研究进展[J]. 化工学报, 2018, 69(1): 317-324.
SHEN Jiani, HE Yijun, MA Zifeng. Research progress of model-based estimation methods for SOC and SOH of lithium ion batteries[J]. Journal of Chemical Engineering, 2018, 69(1): 317-324.
- [5] 孙立珍. 锂离子电池SOC估计方法研究[D]. 呼和浩特: 内蒙古工业大学, 2019.
SUN Lizhen. Research on SOC estimation method of lithium ion battery [D]. Huhhot: Inner Mongolia University of Technology, 2019.
- [6] 周韦润, 姜文刚. 基于遗传算法优化扩展卡尔曼滤波的锂电池SOC估计[J]. 重庆理工大学学报(自然科学), 2019, 33(9): 33-39.
- ZHOU Weirun, JIANG Wengang. Lithium battery SOC estimation based on genetic algorithm optimized extended Kalman Filter[J]. Journal of Chongqing University of Technology(Natural Science), 2019, 33(9): 33-39.
- [7] Ma Y, Li X, Li G, et al. SOC oriented electrochemical-thermal coupled modeling for lithium-ion battery[J]. IEEE Access, 2019, 7: 156136-156149.
- [8] FANG Linlin, LI Junqiu, PENG Bo. Online estimation and error analysis of both SOC and SOH of lithium-ion battery based on DEKF method [J]. Energy Procedia, 2019, 158: 3008-3013.
- [9] 姚芳, 张楠, 黄凯. 估算锂电池SOC的基于LM的BP神经网络算法[J]. 电源技术, 2019(9): 1453-1457.
YAO Fang, ZHANG Nan, HUANG Kai. BP neural network algorithm based on LM for estimating SOC of lithium battery[J]. Chinese Journal of Power Sources, 2019(9): 1453-1457.
- [10] 杨云龙. 基于改进型神经网络动力电池SOC估计研究[D]. 成都: 电子科技大学, 2019.
YANG Yunlong. Research on SOC estimation of power battery based on improved neural network[D]. Chengdu: University of Electronic Science and Technology of China, 2019.
- [11] 耿攀. 基于LSTM循环神经网络的电池SOC预测方法[J]. 上海海事大学学报, 2019, 40(3): 120-126.
GENG Pan. Battery SOC prediction method based on LSTM recurrent neural network[J]. Journal of Shanghai Maritime University, 2019, 40(3): 120-126.
- [12] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Tkde, 2010, 22(10): 1345-1359.
- [13] GHIFARY M, KLEIJN W B, ZHANG M. Domain adaptive neural networks for object recognition[C]//Pacific Rim International Conference on Artificial Intelligence. Springer, Cham, 2014: 898-904.