

doi:10.3969/j.issn.1673-3142.2020.11.014

基于 LSTM 的电动汽车 SOC 估算方法的研究

马非凡¹, 黄碧雄¹, 严晓¹, 王东征², 王炯耿³

(1. 201620 上海市 上海工程技术大学机械与汽车工程学院; 2. 201620 上海市 上海玖克生储能科技有限公司;
3. 310000 浙江省 杭州市 浙江华云信息科技有限公司)

[摘要] 电池包电荷状态 (SOC) 的估算是描述电池包健康状态、电池放电效能的重要指标, 更是驾驶员对电池包剩余电量的最直观感受。基于此, 本文提出了利用长短记忆模型的循环神经网络 (LSTM-RNN) 的模型估算车载电池包的电荷状态 (SOC), 代替传统卡尔曼滤波法 (KF) 进行 SOC 估算的方式。LSTM 是一种纯数据驱动的在线学习以及预测的模型, 节省了在实验室长期试验测量的工作成本。训练结果表明, LSTM 具有足够的准确性和泛化性。

[关键词] 锂电池; 管理系统; 长短记忆; 电荷状态 (SOC); 估算方法

[中图分类号] TM912 [文献标志码] A [文章编号] 1673-3142(2020)11-0060-04

Research on SOC Estimation Method of Electric Vehicle Based on LSTM

Ma Feifan¹, Huang Bixiong¹, Yan Xiao¹, Wang Dongzheng², Wang Jiongeng³

(1. School of Mechanical and Automotive Engineering, Shanghai University of Engineering Sciences, Shanghai 201620, China;

2. Shanghai Makesens Energy Storage Technology Co., Ltd., Shanghai 201620, China;

3. Zhejiang Huayun Information Technology Co., Ltd., Hangzhou City, Zhejiang Province 310000, China)

[Abstract] The estimation of the state of charge (SOC) of the battery pack is an important indicator for describing the health status of the battery pack and the discharge performance of the battery, and SOC is also the most intuitive feeling of the driver for the remaining power of the battery pack. This paper proposes a model of cyclic neural network (LSTM-RNN) using long and short memory model to estimate the state of charge (SOC) of the vehicle battery pack, instead of the traditional Kalman filter (KF) method for SOC estimation. LSTM is a pure data-drive online learning and predictive models, which saves the working cost of long-term test measurements in the lab. The training results show that LSTM has sufficient accuracy and generalization.

[Key words] lithium battery; management system; LSTM; state of charge (SOC); estimation method

0 引言

新能源汽车产业的蓬勃发展使我国电动汽车保有量逐年增加, 并在云端积累了大量的数据, 为电动汽车数据挖掘提供了可能^[1]。

电池状态 (state-of-charge)^[2] 的估算是衡量锂电的健康状态和电动汽车可靠运行的重要指标, 因为电池状态直接反应电池包当前的充放电区间 (判断是否过充、过放等), 并间接描述了电动汽车的续航里程等。然而 SOC 的估算却是一个十分复杂的计算过程, 因为电池在实际工作中不断重复着加速和减速的动态过程, 不能保证电池包的恒功率充放电, 并且没有直接的方法可以快速计算电池的 SOC, 因此准确估算 SOC 对于新能源汽车的行业发展有积极意义。

SOC 被定义为电池组剩余电量, 由电池的剩余电量除以其标称容量得到。通常 SOC 的估算是由电池包的工作温度和充电 / 放电电流变化的非线性函数决定的。传统 SOC 预测方法主要有 2 种^[3]: 基于开路电压的 SOC 估算方法和安时积分法。开路电压法需要测量开路电压进行估算, 但是在实际应用场景中, 电池一直处于供电状态, 因此开路电压很难测量; 安时积分法虽然可以直接根据测量的电流与时间积分求得, 但是仍不能解决由于电池自放电造成的累计误差。

文献 [4-7] 引入卡尔曼滤波法, 结合电化学方程方法, 对电池包的 SOC 进行状态估算, 但需要为模型设计 HPPC 标准试验, 并根据所设计的 RC 电路模型 (戴维宁模型) 计算电池的欧姆内阻值和极化内阻值, 其实验周期较长, 对设备

收稿日期: 2019-11-28 修回日期: 2019-12-13

精度要求高, 成本太高, 不易实现; 更重要的是在真实的使用过程中, 电池内阻会随着电池老化而上升, 造成预估精度下降。

本文将利用 RNN-LSTM 的深度学习算法估算电池的 SOC, 其算法优势如下:

(1) 将电流、电压、速度、温度作为 RNN-LSTM 模型的特征输入, 这些特征直接通过汽车 BMS 信号采集获得, 途径简单且数据有效。相比较传统 SOC 估算中使用的卡尔曼滤波法, RNN-LSTM 模型避免了使用计算密集型滤波器和推导算法, 从而降低硬件计算能耗。

(2) RNN-LSTM 是一种反向传播算法, 能通过训练集数据学习调节网络参数, 并通过梯度下降法得到最优解, 这与传统的等效电路或者电化学模型形成鲜明的对比, 不再需要设计复杂的实验, 和花费大量的时间进行数据的整理和参数计算。

(3) 传统 SOC 估算方法只能计算同一温度下的 SOC, 对于不同温度下的电池 SOC, 需要通过插值法进行估算, 而 RNN-LSTM 模型经过数据训练后可以满足不同温度下的电池 SOC 估算需求, 模型具更强的泛化能力, 以应对电动汽车的动态工作环境。

1 RNN-LSTM 算法原理

自从机器学习算法诞生以来, AI 算法和深度学习算法已经在机器视觉和文本分析等领域先后取得令人瞩目的成就, 百度团队研发的一套基于深度学习的新一代深度语音识别系统 Deep Speech 2, 目前的识别准确率可达到 97%, MIT 科技评论更是将它评为“2016 年十大突破技术”之一, 并认为这项技术将在几年内极大改变人们的生活^[8]。

LSTM 是 RNN 反馈神经网络的一种^[9], 在语音识别、文本分析领域已经取得较好成绩, 其结构示意图如图 1 所示。LSTM 模型可以通过映射输入序列到输出序列来表示非线性的动态函数关系。当我们利用 RNN-LSTM 模型进行电动汽车 SOC 预测时, 我们需要构造形如 $D = \{(\psi_1, SOC_1), (\psi_2, SOC_2), \dots, (\psi_n, SOC_n)\}$ 的数据形式, 其中, SOC_k 表示 k 时刻电动汽车 SOC 的真实值或者观察值; ψ_k 是一个集合, 表示 k 时刻的输入矩阵; 输入变量 ψ_k 被定义为 $\psi_k = [V(k), I(k), T(k), S(k)]$, 其中 $V(k)$ —— k 时刻采集的电压;

$I(k)$ —— k 时刻采集的电流; $T(k)$ —— k 时刻采集的温度; $S(k)$ —— k 时刻车辆行驶速度。




图 1 LSTM 网络结构图

Fig.1 LSTM network structure diagram

一个标准的 LSTM 单元的结构如图 2 所示。与传统 RNN 神经网络相比, LSTM 在其结构基础上增加了一个记忆单元 C_k , 用于储存之前计算的单元的依赖关系, 避免了模型在训练过程中会出现梯度爆炸的现象^[10]。在训练过程中, 模型中的输入门、输出门和遗忘门允许 LSTM 网络判断信息是否要写入记忆门中去。




图 2 LSTM 单元结构图

Fig.2 LSTM unit structure diagram

本文将采用 Tensorflow 结合 Keras, 搭建 LSTM 反馈神经网络, 对 Python 脚本处理好的数据进行预模型训练。LSTM 单元结构主要由输入门、遗忘门、记忆门和输出门构成:

输入门如式 (1) 所示:

$$i_k = \eta(W_{\psi_i} \psi_k + W_{h_i} h_{k-1} + b_i) \quad (1)$$

遗忘门如式 (2) 所示:

$$f_k = \eta(W_{\psi_f} \psi_k + W_{h_f} h_{k-1} + b_f) \quad (2)$$

记忆门如式 (3) 所示:

$$c_k = f_k C_{k-1} + i_k \tanh(W_{\psi_c} \psi_k + W_{h_c} h_{k-1} + b_c) \quad (3)$$

输出门如式 (4) 所示:

$$o_k = \eta(W_{\psi_o} \psi_k + W_{h_o} h_{k-1} + b_o) \quad (4)$$

隐含状态如式 (5) 所示:

$$h_k = o_k \tanh(c_k) \quad (5)$$

式中: 初始隐含层状态 h_0 的初始值为一个 0 矩阵; η ——一个 sigmoid 函数; i, f, c, o ——输入门、遗忘门、记忆门和输出门。之所以称它们为门,

是因为 sigmoid 函数的特殊性, 它能够将输入值变为 0 矩阵的输出, 具有抑制信息传送到下一个计算节点的能力, 并且每个门都拥有一组由 W 表示的网络权重。 W 的下标描述了 2 个分量之间的转换关系, 比如两端的输入-输出门的矩阵用 W_{ψ_0} 表示, 而中间的隐含层的输入-输出门矩阵用 W_{hi} 表示。偏置值 b 被添加到每个门的矩阵乘法, 以增加网络的灵活性, 使得计算结果能够尽可能地接近真实值。最终, 全连接层对隐含层状态张量 h_k 做线性变换, 求得在时间步长为 k 的 SOC 估算值, 公式为

$$SOC_k = V_{out} h_k + b_y \quad (6)$$

其中, V_{out} 和 b_y 表示全连接层的权重矩阵和偏置值, LSTM-RNN 的估算 SOC 与测量的 SOC 之间的差值作为损失函数, 如式 (7) 所示:

$$L = \sum_{k=0}^N \frac{1}{2} (SOC_k - SOC_k^*)^2 \quad (7)$$

式中: N ——序列的长度; SOC_k ——SOC 在 k 时刻的估算值; SOC_k^* ——SOC 在 k 时刻的真实值, 当训练数据被馈送到网络时开始正向传递, 并且在每个时间步骤产生 SOC 估算值以及计算误差和总损耗时。但是作为反馈神经网络, 其结构特点是每一次迭代 ε 过程都包括一个向前传播和一次向后传播, 每一次反馈过程都会达到更新权重矩阵 W 和偏置值 b 的目的。为此, 本文采用一种名为 ADAM 的优化方法, 根据损失函数的梯度更新网络权重和偏置值。其主要公式如下:

$$\begin{aligned} m_\varepsilon &= \beta_1 m_{\varepsilon-1} + \nabla L(W_{\varepsilon-1}) \\ r_\varepsilon &= \beta_2 r_{\varepsilon-1} + \nabla L(W_{\varepsilon-1})^2 \\ \tilde{m}_\varepsilon &= m_\varepsilon / (1 - \beta_1^\varepsilon) \\ \tilde{r}_\varepsilon &= r_\varepsilon / (1 - \beta_2^\varepsilon) \\ W_\varepsilon &= W_{\varepsilon-1} - \alpha \frac{\tilde{m}_\varepsilon}{\tilde{r}_\varepsilon - \chi} \end{aligned} \quad (8)$$

式中: L ——损失函数; β_1 , β_2 初始值分别设置为 0.9 和 0.98; α ——训练步长; K ——常数设置为 10-8; W_ε ——当前训练时期的网络参数矩阵, 可以是 W_{ψ_i} , W_{hi} , W_{ψ_f} 等占位符。模型仅在训练期间, 执行前向和后向传递以持续更新网络权重, 直到达到满足收敛标准为止。通过反向传递, 网络自学其权重, 与需要建立电化学模拟电路、设计实验确定参量的传统 SOC 估算策略相比有显著的改进。

在模型的验证期间, 仅需要向模型提供前一刻的 SOC 和此刻的电流、电压、温度以及速度

就可以得到 SOC 的估算值, 因为在模型的训练过程中就已经确定了模型的网络参数。机器学习的优势是: 一旦训练结束, 模型网络中的权重 W 矩阵就已经确定, RNN-LSTM 只需要按部就班地完成向前传播就行, 降低了计算节点的开销, 而且有利于算法布置到底层硬件, 降低硬件在使用算法时的能耗。而且一般来说, 这比其他可能包含微分方程的算法计算密集程度更低, 因为经过训练的 RNN-LSTM 模型可以适应不同温度的需求, 而不要像传统微积分方程等需要查表调节参数, 因此与传统电池模型相比, 减少了为不同环境温度存储不同参数所需的存储器。上述优点使得 LSTM-RNN 成为电池组中对电池 SOC 进行估算的有效且可行的方法之一。

2 模型验证

本文所采用数据来自上海市新能源汽车公共数据采集与监测研究中心所采集的纯电动车数据, 通过观察一辆电动汽车某一次出行前 12 000 s 的电池输出功率数据, 其功率随时间的变化关系如图 3 所示。该电动车在行驶的前 12 000 s 内, 功率的最大值达到 95 kW, 并且在行驶过程中, 电压不断变化, 在 740 s 的时刻, 司机有一次制动过程, 触发电动车的馈电机机制, 造成电流反向流动, 吸收制动力, 电池处于充电状态, 所以, 在真正的行驶过程中, 电动汽车的电流、功率不断变化, 不能找到一个合适的线性函数对行驶过程进行描述。




图 3 行驶过程中功率输出图

Fig.3 Power output during driving

本文将采用前 1 300 s 的数据作为训练样本, 来预测 1 300 s 以后的电动汽车电池包的 SOC, 其数据分布如图 4 所示。从 SOC 随驾驶时间 (driving_time) 的变化趋势可以看出, 虽然汽车在行驶过程中有馈电现象, 但是整体还是呈下降趋势, 图中 SOC 平台表示, 此时的汽车处于静

止速度为0的状态。




图4 SOC预测曲线

Fig.4 SOC prediction curve

模型的训练以及测试结果如图5所示。从图中可以发现,RNN-LSTM算法在训练集上迭代次数达到7次时,训练MAE值下降速度减小,MAE最小值为0.0112,模型已经达到最优解,在测试集上模型的MAE值最小值为0.0111,所以RNN-LSTM算法能够准确估算SOC,满足实际电动汽车的应用需求。




图5 平均绝对误差与迭代次数关系曲线

Fig.5 MAE and iteration number relationship curve

3 结论

关于锂电池SOC的估算研究国内外早已开始,但是在实验室基本围绕单体进行研究,利用

传统建模方式估算SOC值。本文提出利用RNN-LSTM机器学习的方式对整包SOC进行预估,只需要向模型提供电流、电压、温度以及行驶车速,经过模型的训练,就可以确定网络中的参数估算电池整包SOC值。本文所设计的模型能够满足电池包在不同温度、不同工况下SOC估算需求,通过实际运营数据验证了算法的合理性。也可以考虑在未来工作中作为电池诊断的一种策略。

参考文献

- [1] 马科磊,柯小霞.新能源汽车产业经营业绩的分析与评价[J].中国商论,2019(10).
- [2] Pang S, Farrell J, Du J, et al. Battery state-of-charge estimation[C]//American Control Conference,2001. Proceedings of the 2001. IEEE, 2001.
- [3] 孙骏,李宝辉,薛敏.电动汽车SOC估算方法[J].汽车工程师,2011(12):27-29+36.
- [4] 石刚,赵伟,刘珊珊.基于无迹卡尔曼滤波估算电池SOC[J].计算机应用,2016,36(12):3492-3498.
- [5] 赵凯,朱黎明.无迹卡尔曼滤波的电池荷电状态估计试验研究[J].汽车工程学报,2013,3(5):332-337.
- [6] Do D V, Forgez C, El K B K, et al. Impedance observer for a Li-ion battery using Kalman filter[J]. IEEE Transactions on Vehicular Technology, 2009, 58(8): 3930-3937.
- [7] Jian Longhuang, Ying Nanwang, Zhong Fengwang, et al. The experiments of dual Kalman filter in lithium battery SOC estimation[J]. Applied Mechanics and Materials, 2014, 2963: 1509-1512.
- [8] 何清,李宁,罗文娟,等.大数据下的机器学习算法综述[J].模式识别与人工智能,2014,27(4):327-336.
- [9] Graves A. Supervised sequence labelling with recurrent neural networks[M]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012.
- [10] Sainath T N, Vinyals O, Senior A, et al. Convolutional, long short-term memory, fully connected deep neural networks[C]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2015.

作者简介 马非凡(1993—),男,硕士研究生,研究方向:新能源汽车动力电池。E-mail: mafeifan_mr@163.com